

Análise de Componentes Independentes

Aluno: Samuel Cavalcanti

1 Breve descrição do algoritmo

O algoritmo FastICA pode ser derivado tanto para o caso de maximizar a não- gaussianidade utilizando o método kurtosis quanto o método negentropia. A diferença básica entre os algoritmos será a iteração que calculará o novo w . Abaixo segue o algoritmo utilizando o método negentropia

1. Escolher um vetor de pesos w inicial (por exemplo, aleatoriamente).
2. $W^* \leftarrow E\{zg(w^t z)\} - E\{zg'(w^t z)\}w$
3. $w \leftarrow \frac{w^*}{\|w^*\|}$
4. Se não convergiu, voltar ao passo 2.

Como função g as derivadas das funções descritas nas equações 1 e 2 podem ser utilizadas (equações 3 e 4), pois resultam em boas aproximações da negentropia. Além dessas funções, pode-se utilizar também a derivada do momento de quarta ordem, que resultará no método kurtosis (equação 5).

$$G_1(y) = \frac{1}{a_1} \log(\cosh(a_1 y)) \quad (1)$$

$$G_2(y) = -e^{-\frac{y^2}{2}} \quad (2)$$

$$g_1(y) = \tanh(a_1 y) \quad (3)$$

$$g_2(y) = \frac{y}{2} e^{-\frac{y^2}{2}} \quad (4)$$

$$g_3(y) = y^3 \quad (5)$$

O critério de convergência é o novo e antigo w apontarem para a mesma direção (considerando que w e $-w$ são iguais).

Abaixo seguem algumas propriedades do algoritmo FastICA:

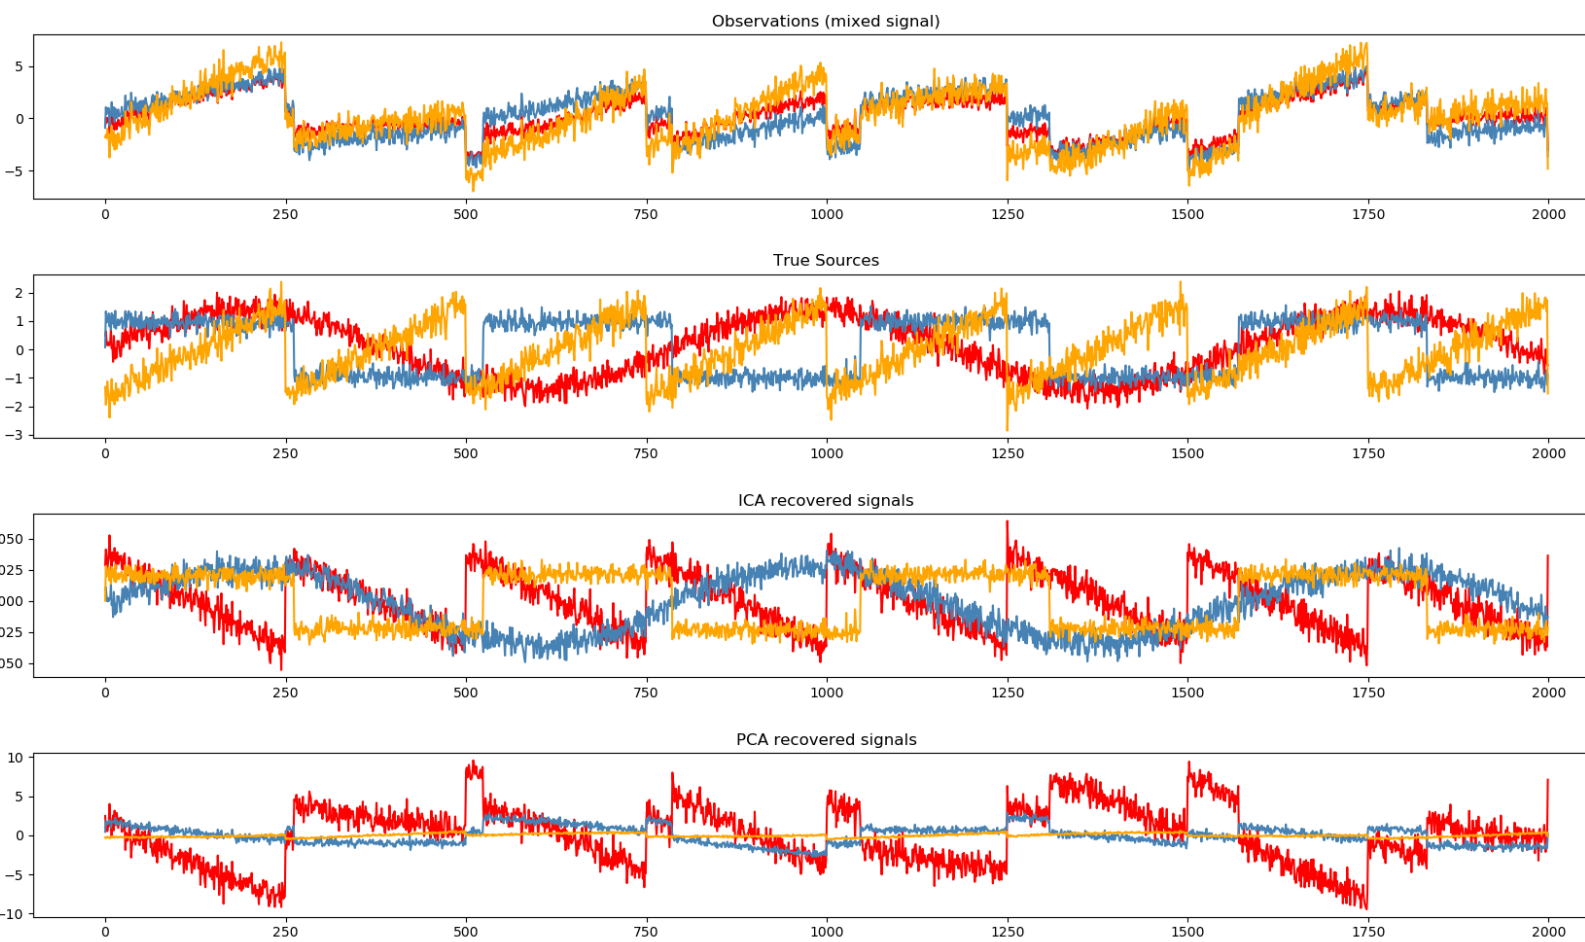
1. A convergência é cubica (ou pelo menos quadrática), sob a suposição do modelo de dados ICA. Isto contrasta com outros algoritmos ICA baseados em métodos de gradiente descendente, onde a convergência é somente linear. Isto significa uma rápida convergência para o algoritmo FastICA. Diversos experimentos em dados em tempo real comprovam esta propriedade.
2. Contrário a algoritmos baseados em gradiente, não há nenhum parâmetro de taxa de aprendizagem para escolher, o que torna o FastICA mais simples.
3. O algoritmo encontra diretamente as componentes independentes de praticamente qualquer distribuição não-gaussiana usando qualquer medida de não-linearidade g , ao contrário de muitos algoritmos onde a medida de não-linearidade precisa ser escolhida especificamente
4. O desempenho do algoritmo pode ser melhorado com a escolha adequada de uma medida de não-linearidade.
5. As componentes independentes podem ser estimadas uma a uma, o que diminui o custo computacional em casos onde somente algumas das componentes independentes precisam ser estimadas.
6. O algoritmo FastICA possui outras vantagens como: paralelismo, é distribuído, computacionalmente simples e requer pouco espaço de memória.

[1]

2 Problema Exemplo

O trabalho escolhido foi sobre o ICA. Mais precisamente sobre o fastICA. Nesse exemplo o [scikit-learn](#) mostra o funcionamento do Fast ICA em comparação com o PCA para a separação de 3 sinais combinados. Nesse exemplo podemos observar que PCA não consegue separar as 3 fontes por causa da não-gaussianidade da amostra. No Entanto o Fast ICA conseguiu.

Figura 1: scikit-learn exemplo



Referências

- [1] Silva, Alan Paulo Oliveira, *Uma implementação da análise de componentes independentes em plataforma de hardware reconfigurável*, Universidade Federal do Rio Grande do Norte, 2010.